

# 基于多任务学习的图神经网络推荐模型研究<sup>\*</sup>

罗可劲, 刘广聪, 杨文浩

(广东工业大学计算机学院, 广东 广州 510006)

**摘要:** 图神经网络处理非欧氏空间数据的强大能力促使越来越多的研究将其应用于推荐领域。然而, 现有的基于图神经网络的推荐模型大多数仍然采用多个邻接矩阵来表示多种节点或边属性等异质信息, 没有充分利用异质信息之间的交互。因此, 提出一种新型的图神经网络推荐模型, 把所有信息实体之间的丰富交互建模成异质图, 并在异质图上使用稠密子图采样策略进行子图采样; 此外, 模型还加入多任务学习方法用于共同优化链接预测与推荐任务, 使得模型学习到更好的节点表示, 以提升推荐效果。2 个公开数据集上的实验结果表明, 所提模型相比基线模型, 在 Top-N 推荐任务性能上有所提高。

**关键词:** 推荐系统; 图神经网络; 多任务学习

**中图分类号:** TP391

**文献标志码:** A

**doi:** 10.3969/j.issn.1007-130X.2023.04.020

## A graph neural network recommendation model based on multi-task learning

LUO Ke-jin, LIU Guang-cong, YANG Wen-hao

(School of Computer Science and Technology, Guangdong University of Technology, Guangzhou 510006, China)

**Abstract:** The powerful ability of graph neural network to process non-Euclidean spatial data has prompted more and more people to pay attention to its application in the recommendation field. However, most of the existing recommendation models based on graph neural networks still use several adjacency matrices to represent heterogeneous information such as all kind of nodes or edge attributes, and fail to make full use of the interaction of heterogeneous information. Therefore, this paper proposes a new graph neural network recommendation model, which models the rich interactions between all information entities as heterogeneous graph and uses the dense subgraph sampling strategy for sampling the subgraphs of heterogeneous graph. In addition, the multi-task learning method is added to the model to jointly optimize the link prediction and recommendation tasks, so that the model learns a better node representation and effectively improves the recommendation results. Experiments on two public datasets show that, compared with the baseline models, the proposed model improves the performance of the Top-N recommendation task.

**Key words:** recommender system; graph neural network; multi-task learning

## 1 引言

中文推荐系统如今已经被广泛用于帮助电子商务的用户更方便地找到相关内容、产品和服务。

推荐系统提供的个性化推荐内容通常是根据用户与项目的历史交互行为中隐含的关联信息进行用户偏好预测的结果。由于推荐场景的对象交互可以视为图进行数据挖掘, 推荐系统的对象之间建模成二分图或异质图进行相似度计算, 进而预测用户

<sup>\*</sup> 收稿日期: 2021-06-01; 修回日期: 2021-10-22  
基金项目: 国家自然科学基金(61672007)  
通信作者: 刘广聪(liugc@gdut.edu.cn)  
通信地址: 510006 广东省广州市广东工业大学计算机学院  
Address: School of Computer and Technology, Guangdong University of Technology, Guangzhou 510006, Guangdong, P. R. China

偏好并推荐感兴趣的内容<sup>[1,2]</sup>。

此外,基于图神经网络 GNN(Graph Neural Network)的推荐算法具有扩展性强、可解释等特点,也是备受关注的推荐算法之一。图神经网络能直接从二分图中提取用户与项目的交互信息,得到嵌入表示用于推荐任务,但这类方法的推荐性能会局限于交互信息的单一性。另一方面,图神经网络尽管可以在多类型节点或边的异质图中聚合丰富的语义信息,让用户与项目的节点表示融入更多信息。然而,这类基于异质图的方法也存在许多问题,例如对不同类型的节点或边单独维护不同的非共享权重参数,导致无法充分捕捉异质特征信息,以及单独构建不同关系的邻接矩阵需要消耗巨大的内存,对训练模型的硬件要求较高等问题。

针对上述问题,本文进行了如下研究:

(1)使用稠密子图采样策略进行节点采样并重构邻接矩阵用于分批训练,避免了为不同类型节点之间构建多个邻接矩阵,进而减少模型的空间复杂度。

(2)在图神经网络模型中采用多任务联合训练方法,通过多任务学习中的特征共享和联合优化,共同作用于模型的更新,让模型的泛化能力更强,有效地提升推荐性能。

(3)对不同训练任务的损失加入权重学习,在训练过程中利用每个任务的损失来调整任务之间的关系,避免联合训练导致的负迁移学习带来的推荐系统性能下降。

## 2 相关工作

### 2.1 图神经网络

图神经网络是一种可以对非欧氏空间数据进行特征提取的模型。其中,基于消息传递机制<sup>[3]</sup>的图神经网络框架的计算流程定义如下所示:

**定义 1** GNN 框架的节点表示生成过程:

(1)聚合:对目标节点的邻域节点信息进行聚合;

(2)池化:通过聚合操作得到本层的节点邻域信息,与上一层的源节点表示进行池化操作后作为本层的目标节点表示,其形式化表示如式(1)所示:

$$\mathbf{h}_v^k = \text{Pool}^{(k)}(\mathbf{h}_v^{k-1}, \text{Aggregate}_{u \in N(v)}^k(\mathbf{h}_u^{k-1})) \quad (1)$$

其中,  $\mathbf{h}_v^k$  是节点  $v$  在 GNN 中第  $k$  层的节点表示;  $N(v)$  表示节点  $v$  的邻域节点;  $\text{Aggregate}(\cdot)$  表

示聚合邻域节点信息的函数;  $\text{Pool}(\cdot)$  表示筛选信息的函数,具体可以是取最值、取均值等操作。

由于图数据的结构化信息和节点关系可以作为先验知识和交互约束,以图卷积神经网络<sup>[4]</sup>为代表的图神经网络模型可以解释模型特征提取的过程。当把推荐系统中各种类型节点建模成图结构的时候,图神经网络聚合信息的过程等同于挖掘推荐系统下每个对象之间的关联信息,可以使得模型更具有可解释性。

### 2.2 异质图表示学习

异质图表示学习包含了对现实世界中许多不同类型的对象及其复杂关系的许多重要抽象。相关定义如下所示:

**定义 2** 异质图:异质图定义为有向图  $G = (V, E, \varphi, \psi)$ , 其中每个节点  $v \in V$  和每条边  $e \in E$  分别与对象类型映射函数  $\varphi(v): V \rightarrow A$  和  $\psi(e): E \rightarrow R$  相关联,其中  $|A|$  和  $|R|$  分别代表节点类型数和边类型数,且满足  $|A| + |R| > 1$ 。

**定义 3** 元路径<sup>[5]</sup>:元路径  $P$  是异质图上定义的路径:  $A_1 \xrightarrow{R_1} A_2 \xrightarrow{R_2} \dots \xrightarrow{R_{l-1}} A_l$ 。具体来说,元路径将顶点类型  $A_1, A_2, \dots, A_l$  间的复合关系描述为  $R = R_1 \circ R_2 \circ \dots \circ R_{l-1}$ , 其中“ $\circ$ ”表示关系上的合成运算符。

**定义 4** 元关系<sup>[6,7]</sup>:元关系  $\langle \varphi(s), \psi(e), \varphi(t) \rangle$  表示从源节点  $s$  连接到目标节点  $t$  的边  $e = (s, t)$  的关系类型。

异质图表示学习的研究可以简单分为浅层模型和深层模型<sup>[8]</sup>。浅层模型通常将异质网络分解成简单网络后再各自进行表示学习。HIN2Vec(Heterogeneous Information Networks to Vector)<sup>[9]</sup>通过同时考虑不同类型节点及其关系,学习节点以及元路径的表示。Metapath2vec(Metapath to vector)<sup>[10]</sup>则使用基于元路径扩大随机游走策略生成聚合到多种节点类型语义信息的节点表示。深层模型是直接通过深度神经网络抽取异质图中节点所蕴含的复杂语义信息来生成表示向量。HAN(Heterogeneous graph Attention Network)<sup>[11]</sup>使用元路径作为边来扩充图并基于元路径的边维护不同的权重矩阵,进而聚合来自不同元路径的信息。HetSANN(Heterogeneous graph Structural Attention Neural Network)<sup>[12]</sup>是通过目标任务引导直接对原始异质图进行图结构卷积操作学习结构信息来生成嵌入表示的方法。

### 2.3 基于图神经网络的推荐算法

推荐算法需要解决的问题是如何有效地给用户

推荐感兴趣的项目。用户与项目之间的交互可以视为二分图,而在需要加入另外的实体对象的时候,又可以建模成具有不同类型节点和边属性的异质图。因此,推荐任务可以转换成图结构数据挖掘任务,图神经网络可以在推荐系统领域得到广泛应用。

PinSage (Pins graph Sample and aggregate)<sup>[13]</sup>使用图神经网络提取图结构和节点的特征信息,生成节点嵌入表示并用于推荐任务。GC-MC(Graph Convolutional Matrix Completion)<sup>[14]</sup>通过一种基于消息传递的图自编码器进行矩阵补全,预测未知项目的概率评分用于推荐。NGCF(Neural Graph Collaborative Filtering)<sup>[15]</sup>通过图神经网络将节点之间的高阶连通性编码进入节点表示向量,再据此给出有效的推荐。SR-GNN(Session-based Recommendation with Graph Neural Networks)<sup>[16]</sup>将推荐场景的会话序列建模成图结构数据并利用图神经网络预测用户操作。GATNE(General ATtributed multiplex heterogeneous Network Embedding)<sup>[17]</sup>可以捕获不同节点和边类型以及它们之间的属性信息,可应用于大规模多元异质属性网络的推荐场景。MEIRec(Meta-path-guided Embedding method for Intent Recommendation)<sup>[18]</sup>将推荐系统建模成异质图后利用元路径引导聚合不同类型节点邻居信息,并对节点进行统一嵌入表示。NIRec(Neighborhood-based Interaction model for Recommendation)<sup>[19]</sup>在推荐系统的多种类型对象交互中基于元路径的邻居选择并利用注意力机制聚合节点级和路径级特征信息来生成节点表示。

## 2.4 多任务学习

多任务学习 MTL(Multi-task Learning)是一种通过共享相关任务之间监督信号中的领域知识来改善原始任务泛化能力的机器学习方法。多任务学习的模式主要是模型的隐层参数共享,常用的2种共享参数方法为:硬参数共享和软参数共享<sup>[20]</sup>。硬参数共享是共享所有任务之间的隐含层,同时保留多个特定任务的输出层;软参数共享则是对每个任务都定义对应的模型和参数,然后通过正则化模型参数使得参数分布相似。

在工业界推荐领域,阿里巴巴通过对模型引入辅助任务进行多任务联合训练缓解电商推荐中存在的问题<sup>[21]</sup>;Google提出了多门混合专家算法用于学习任务之间的关系,缓解任务差异带来的负迁移效果<sup>[22]</sup>;腾讯为了解决多任务学习中的“跷跷板”现象,提出了一种新型多任务学习个性化推荐

模型<sup>[23]</sup>。显然,多任务学习不仅可以提高模型的泛化能力,还可以同时实现多个任务需求,减少模型维护成本。

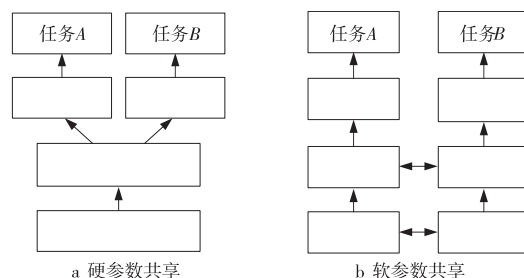


Figure 1 Two types of parameter sharing

图1 2种类型的参数共享

## 3 研究内容

本文提出的基于多任务学习的图神经网络推荐模型 MTHGT (Multi-Task Heterogeneous Graph Transformer)如图2所示,主要包括3个部分:稠密子图采样策略、基于多任务学习的图神经网络和多任务联合训练。

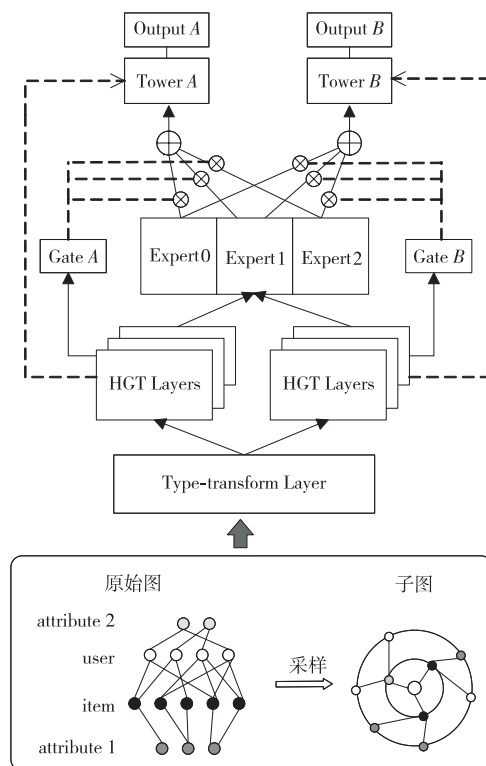


Figure 2 Network architecture of MTHGT

图2 MTHGT网络模型结构

### 3.1 稠密子图采样策略

#### 3.1.1 策略介绍

由于异质图中的各节点类型的度分布和节点

数量相差较大,直接对异质图随机采样会导致子图中不同类型的节点或边的数量高度不平衡。所以,本文使用稠密子图采样策略处理异质图,基本思想是从原始图中采样若干个节点作为节点池,然后对所有采样节点计算其节点类型  $v_{\varphi(t)} \in V_{\varphi(t)}$  的采样概率,如式(2)所示:

$$P(v_{\varphi(t)}) = \frac{v_{\varphi(t)}^2}{\|V_{\varphi(t)}\|_2^2} \quad (2)$$

其中,  $V_{\varphi(t)}$  表示类型  $\varphi(t)$  的所有节点。

稠密子图采样策略每次生成子图时都根据采样概率在节点池中采样节点,可以避免多次采样到节点度更大的节点,使得子图中每种类型节点和边有相似的数量,保证了子图的稠密性,减少了信息损失和样本方差。

### 3.1.2 空间复杂度分析

本文采用稠密子图采样策略是通过将异质图拆分成多个异质子图,代替使用多个邻接矩阵表示异质图的方法,进而在分批训练中减少每个批次机器所需的内存空间,以及在节点类型特征提取过程中共享参数,减少参数量。其中,多个邻接矩阵表示异质图的典型方法是基于元路径的邻接矩阵,本文方法是使用稠密子图采样。假设训练数据中有  $k$  种节点类型,节点数量为  $N$ ,每种类型节点数量为  $N_{\varphi(v)}$ ,子图节点采样数目为  $p$  且  $p \ll N_{\varphi(v)}$ ,元路径数量为  $m$ ,节点向量维度为  $d$ ,则 2 种方法的空间复杂度对比如表 1 所示。

Table 1 Comparison of space complexity

表 1 空间复杂度比较

算法模块	方法	
	稠密子图采样	基于元路径的邻接矩阵
批次处理	$O(p^2)$	$O(N_{\varphi(v)}^2)$
特征提取	$O(dp)$	$O(mdN_{\varphi(v)})$

根据表 1 中  $p \ll N_{\varphi(v)}$  可得,相比基于元路径的邻接矩阵方法,稠密子图采样方法每批次所需内存空间更少,且在节点类型特征提取过程中能够共享参数矩阵,大大减少了参数量。

## 3.2 基于多任务学习的图神经网络

基于多任务学习的图神经网络架构主要分为 4 个部分:节点类型转换层、图卷积层、混合专家知识层和预测任务层。

### 3.2.1 节点空间转换层

由于不同类型的节点特征存在差异,所以在特征提取之前需要进行节点空间转换,通过低维实体空间中的投影分别对异质顶点进行转换,并维护每

种类型的节点对应的映射矩阵,具体如式(3)所示:

$$\mathbf{H}_{\varphi(v)}^0 = \sigma(\mathbf{W}_{\varphi(v)}^0 \mathbf{x}_v) \quad (3)$$

其中,  $\mathbf{H}_{\varphi(v)}^0$  是经过空间转换后的节点表示;  $\mathbf{x}_v$  表示节点  $v$  的输入特征向量;  $\mathbf{W}_{\varphi(v)} \in \mathbf{R}^{n_h \times n_d}$  表示节点  $v$  类型的映射矩阵;  $\sigma(\cdot)$  表示激活函数。

另外,图卷积层的特征提取过程可能会弱化不同节点类型之间的差异,所以需要将目标节点的表示向量映射回其特定类型的分布,并添加一个残差连接结构用于权衡之前的特征表示与聚合信息后的表示,具体操作形式化如式(4)所示:

$$\mathbf{H}_{\varphi(t)}^k = \alpha(\sigma(\mathbf{W}_{\varphi(t)}^k \hat{\mathbf{H}}_{\varphi(t)}^k)) + (1 - \alpha)\mathbf{H}_{\varphi(t)}^{k-1} \quad (4)$$

其中,  $\mathbf{H}_{\varphi(t)}^k$  是从第  $k$  层网络输出的目标节点表示结果;  $\sigma(\cdot)$  表示激活函数;  $\hat{\mathbf{H}}_{\varphi(t)}^k$  表示经过第  $k$  层网络聚合源节点信息后的目标节点表示;  $\mathbf{W}_{\varphi(t)}^k \in \mathbf{R}^{n_h \times n_h}$  表示目标节点  $t$  的特定类型映射矩阵;  $\alpha$  是可学习的参数。

### 3.2.2 图卷积层

MTHGT 模型的图卷积层模块分别定义了了在异质图上聚合节点信息的 3 个部分:异质互注意力、异质信息传递和特定目标信息聚合。模块结构如图 3 所示。

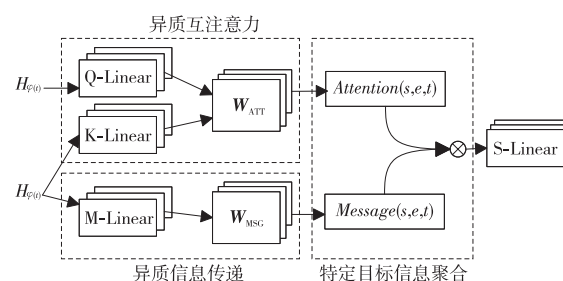


Figure 3 Architecture of graph convolutional layer module

图 3 图卷积层模块结构

异质交互注意力的主要工作是评估每个源节点的重要性。把源节点和目标节点分别投影映射,再把向量矩阵分为  $h$  个注意力头向量,得到对应的  $h$  个 Key 向量  $\mathbf{K}_{\varphi(s)}^i$  和 Query 向量  $\mathbf{Q}_{\varphi(t)}^i$ ;然后在对应的注意力头中根据元关系来计算每个节点对的注意力向量;最后把  $h$  个注意力向量拼接起来进行 softmax 计算,得到源节点对目标节点的注意力权重。具体操作形式化如式(5)~式(7)所示:

$$\mathbf{ATT}_{\forall s \in N(t)}(s, e, t) = \text{softmax}\left(\prod_{i \in \{1, 2, \dots, h\}} \mathbf{H}_{\text{ATT}}^i(s, e, t)\right) \quad (5)$$

$$\mathbf{H}_{\text{ATT}}^i(s, e, t) = (\mathbf{K}_{\varphi(s)}^i \mathbf{W}_{\varphi(e)}^{\text{ATT}} \mathbf{Q}_{\varphi(t)}^i) \cdot \frac{\mathbf{W}_{s, e, t}^{\text{PRI}}}{\sqrt{d}} \quad (6)$$

$$\begin{cases} \mathbf{K}_{\varphi(s)}^i = \text{K-Linear}_{\varphi(s)}^i(\mathbf{H}_{\varphi(s)}) \\ \mathbf{Q}_{\varphi(t)}^i = \text{Q-Linear}_{\varphi(t)}^i(\mathbf{H}_{\varphi(t)}) \end{cases} \quad (7)$$



其中,  $\mathbf{W}_{\psi(e)}^{\text{ATT}} \in \mathbf{R}^{n_h \times n_h}$  是使用  $\langle \varphi(s), \psi(e), \varphi(t) \rangle$  元关系三元组对源节点  $s$  与目标节点  $t$  的边进行参数化定义的权重矩阵,  $\mathbf{W}_{s,e,t}^{\text{PRI}}$  是用于注意力自适应缩放元关系权重矩阵,  $d$  是注意力向量的维度大小。

异质信息传递的主要工作是将信息从源节点传递到目标节点。将源节点表示进行投影映射再分为  $h$  个注意力头向量, 然后再将每个注意力头向量与  $\mathbf{W}_{\psi(e)}^{\text{MSG}}$  权重矩阵相乘得到的  $h$  个消息向量  $\mathbf{H}_{\text{MSG}}^i$  拼接起来。具体操作形式化如式(8)和式(9)所示:

$$\mathbf{MSG}_{\forall s \in N(t)}(s, e, t) = \prod_{i \in \{1, 2, \dots, h\}} \mathbf{H}_{\text{MSG}}^i(s, e, t) \quad (8)$$

$$\mathbf{H}_{\text{MSG}}^i(s, e, t) = M\text{-Linear}_{\varphi(s)}^i(\mathbf{H}_{\varphi(s)}) \cdot \mathbf{W}_{\psi(e)}^{\text{MSG}} \quad (9)$$

其中,  $\mathbf{W}_{\psi(e)}^{\text{MSG}} \in \mathbf{R}^{n_h \times n_h}$  表示融合边依赖的权重矩阵。

特定目标信息聚合的主要工作是将特征分布不同的所有源节点信息聚合到目标节点。具体操作是把计算得到的注意力权重  $\mathbf{ATT}(s, e, t)$  与消息向量  $\mathbf{MSG}(s, e, t)$  相乘得到该层网络聚合源节点信息后的目标节点表示  $\hat{\mathbf{H}}_{\varphi(t)}^l$ , 具体操作形式化如式(10)和式(11)所示:

$$\mathbf{H}_{\varphi(t)}^l = \mathbf{ATT}(s, e, t) \cdot \mathbf{MSG}(s, e, t) \quad (10)$$

$$\hat{\mathbf{H}}_{\varphi(t)}^l = S\text{-Linear}_{\varphi(t)}(\mathbf{H}_{\varphi(t)}^l) \quad (11)$$

### 3.2.3 混合专家知识层

MTHGT 模型的混合专家知识层是以 MMoE (Multi-gate Mixture-of-Experts)<sup>[22]</sup> 作为基础添加了多任务学习的网络结构。MMoE 模块为每个任务都单独分配对应的门控网络, 每个门控网络可以根据任务需求选择专家网络 Experts, 最终对每个 Expert 输出概率加权平均获得每个任务输出。具体操作形式化如式(12)和式(13)所示:

$$E^k(\hat{\mathbf{H}}) = \sum_{i=1}^n g_i^k(\hat{\mathbf{H}}) \cdot f_i(\hat{\mathbf{H}}) \quad (12)$$

$$g^k(\hat{\mathbf{H}}) = \text{softmax}(\hat{\mathbf{H}}) \quad (13)$$

其中,  $g^k(\cdot)$  是第  $k$  个子任务对应的门控网络输出,  $n$  为专家网络  $f_i(\cdot)$  的个数。同时, 为了让高层网络更好地引导图卷积层根据不同任务去抽取信息, 本文对图卷积层内部结构添加了针对不同类型目标节点的残差连接。具体操作形式化如式(14)所示:

$$E^k(\hat{\mathbf{H}}_{\varphi(t)}) = \alpha \hat{\mathbf{H}}_{\varphi(t)} + (1 - \alpha) E^k(\hat{\mathbf{H}}_{\varphi(t)}) \quad (14)$$

其中,  $\hat{\mathbf{H}}_{\varphi(t)}$  为图卷积层的输出;  $\alpha$  是可学习参数,

用于控制不同类型目标节点的表示与混合专家知识层输出进行残差连接得到最终输出的比重。

### 3.2.4 预测任务层

MTHGT 模型中的 2 个学习任务分别是对包括用户与项目的所有节点的链接预测任务和对用户推荐的正负样本进行判断的推荐任务。2 个任务都是通过计算输出的对应节点表示向量内积得到预测结果, 如式(15)所示:

$$\hat{y}(t, s) = \mathbf{e}_t^* \mathbf{e}_s^* \quad (15)$$

其中,  $\hat{y}$  表示最终的预测结果,  $\mathbf{e}_t^* \in E^k(\hat{\mathbf{H}}_{\varphi(t)})$  和  $\mathbf{e}_s^* \in E^k(\hat{\mathbf{H}}_{\varphi(s)})$  分别表示节点  $t$  和节点  $s$  的节点表示。

综上, 本文算法具体步骤如算法 1 所示。

**算法 1** 基于多任务学习的图神经网络推荐算法

**输入:** 用户集  $U$ , 项目集  $I$ , 包括用户、项目及两者属性等多种类型节点的异质图  $G$ , 随机初始化的节点表示  $\mathbf{x}_v$ 。

**输出:** 用户的 Top- $N$  项目推荐列表。

**步骤 1** 对异质图采样稠密子图  $G^* \in G$ , 在子图上每个任务分别进行邻居节点信息聚合, 计算所有目标节点的表示向量:

```
for  $\forall G^* \in G$  do
  for  $\forall v \in G^*$  do
    利用式(3)进行节点类型空间转换;
  end for
  //每个任务分别在对应的图卷积层计算目标节点表示
   $\hat{\mathbf{H}}^{(a)} \leftarrow \text{GNN}(\mathbf{H})$ ;
  :
   $\hat{\mathbf{H}}^{(k)} \leftarrow \text{GNN}(\mathbf{H})$ ;
end for
```

**步骤 2** 在混合专家知识层优化目标节点表示:

$$\hat{E}^{(a)}, \dots, \hat{E}^{(k)} \leftarrow \text{MMoE}(\hat{\mathbf{H}}^{(a)}, \dots, \hat{\mathbf{H}}^{(K)});$$

**步骤 3** 计算推荐任务的用户与项目节点表示向量的内积作为预测分数:

```
for  $\mathbf{e}_u^*, \mathbf{e}_i^* \in \hat{E}^{(k)}$  do
  利用式(15)计算预测分数  $score$ ;
```

**end for**

**步骤 4** 将  $score$  从大到小进行排序, 在项目集  $I$  中选择前  $N$  个项目作为用户集  $U$  中指定用户  $u$  的项目推荐列表。

### 3.3 多任务联合训练

为了进一步改善模型的泛化能力和缩小泛化误差的范围, 本文采用 Automatic Weighted Loss<sup>[24]</sup> 方法改进多任务学习的损失函数, 通过任务之间的损失概率模型的极大似然估计, 不同任务可以学习自身对 MTHGT 模型的权重大小。

假设通过 MTHGT 模型得到 2 个任务的输出

$f_1^w(x)$  和  $f_2^w(x)$ , 当利用同方差不确定性来最大化高斯似然估计时, 可以得到初始的 softmax 输出概率, 如式(16)所示:

$$p(y | f^w(x), \sigma) = \text{softmax}(\frac{1}{\sigma^2} f^w(x)) \quad (16)$$

此时对每个任务的模型输出进行 softmax 的似然估计, 如式(17)所示:

$$\log p(y=c | f^w(x), \sigma) = \frac{1}{\sigma^2} f^w(x) - \log \sum_{c'} \exp(\frac{1}{\sigma^2} f_{c'}^w(x)) \quad (17)$$

其中,  $\sigma$  表示噪声,  $\sigma$  越大, 任务权重越低, 反之则越高。通过这样的动态约束, 模型在训练过程中可以学习到不同任务损失的权重并调整任务之间的关系, 避免联合训练导致的负迁移学习。

## 4 实验及结果分析

### 4.1 实验环境与数据

本文的实验环境为: Intel Xeon Gold 6226R 中央处理器, Nvidia GTX 2080Ti(11 GB)并行计算核心, 16 GB 内存; Ubuntu18.04 操作系统; 编译工具版本为 Python3.7, Pytorch1.7.0, CUDA10.1。

为了验证 MTHGT 模型在不同稀疏性数据上的性能表现, 本文实验选取了公开的 Movielens-1M 和 Last.FM 真实数据集。Movielens-1M 数据集包含用户与电影的交互数据, 以及用户画像信息与电影的相关信息。Last.FM 数据集包含用户之间、用户与歌手之间的交互数据, 以及两者的相关属性信息。为了确保实验结果的可靠性, 本文对数据集做以下处理: 使用五折交叉验证随机划分数据, 80% 作为训练集, 20% 作为测试集, 且保证训练集和测试集的交互数据没有重复。数据集信息如表 2 所示。

Table 2 Datasets of experiments

表 2 实验数据集

数据集	用户数	项目数	交互数	稀疏度/%
Movielens-1M	6 040	3 706	1 000 209	95.16
Last.FM	1 892	17 632	92 834	99.72

### 4.2 实验及评测指标

为了评估 MTHGT 模型的性能, 在上述 2 个数据集上比较以下 4 种模型:

(1) PinSage<sup>[13]</sup>: 基于图卷积网络的模型。在二分图上利用随机游走采样目标节点的邻居节点, 再使用图卷积网络聚合信息生成节点表示向量。

(2) HIN2Vec<sup>[9]</sup>: 基于异质图的表示学习模型。利用节点之间不同元路径来捕捉异质图中嵌入的丰富语义, 生成节点表示向量。

(3) HGT(Heterogeneous Graph Transformer)<sup>[6]</sup>: 基于元关系的异质图神经网络模型。通过元关系参数化节点之间的交互, 构建节点和边类型的注意力机制, 从源节点聚合信息生成目标节点表示向量。

(4) NGCF<sup>[15]</sup>: 基于图神经网络的协同过滤。利用图神经网络捕捉协同信号, 将节点之间的高阶连通性编码进入目标节点表示向量。

在评测模型性能时, 本文采用精确率( $P@N$ )、召回率( $R@N$ )和命中率( $HR@N$ )作为推荐系统的评测指标。精确率( $P@N$ )代表推荐结果中用户喜欢的项目所占的比例; 召回率( $R@N$ )代表测试集中有多少用户喜欢的项目出现在推荐结果中; 命中率( $HR@N$ )代表在 Top- $N$  推荐结果中能够命中用户实际偏好的项目数。各项评测指标的计算如式(18)~式(20)所示:

$$P@N = \frac{|R \cap \hat{R}_{1:N}|}{N} \quad (18)$$

$$R@N = \frac{|R \cap \hat{R}_{1:N}|}{|R|} \quad (19)$$

$$HR@N = \frac{1}{U} \sum_{i=1}^N hits(i) \quad (20)$$

其中,  $R$  是测试集中的目标物品;  $\hat{R}_{1:N}$  是模型预测的 Top- $N$  个项目;  $U$  表示用户总数量;  $hits(i)$  表示第  $i$  个用户的真实交互值是否在推荐列表中, 是为 1, 否则为 0;  $N$  设置为 10。

### 4.3 实验结果分析

#### 4.3.1 评测指标分析

本文提出的 MTHGT 模型与对比模型的性能如表 3 所示。

从表 3 可知, 在实验参数选择最优的情况下, 基于异质图的方法 HIN2Vec 和 HGT 在 2 个数据集上的 3 种评测指标值均优于基于二分图的方法 PinSage 的, 说明异质图方法能够聚合丰富的异质语义信息并提升推荐性能。本文提出的 MTHGT 模型在 2 个数据集上相比其他对比模型均取得了更好的评测指标结果。其中, 在 Last.FM 稀疏数据集上, 相比推荐性能表现较好的基于图神经网络的协同过滤模型 NGCF, MTHGT 模型的精确率、召回率和命中率分别提升了 3.87%, 1.75% 和 4.19%, 说明 MTHGT 模型加入的结构能够缓解

数据稀疏问题并带来增益效果。

Table 3 Experimental results of MTHGT and compared models

表 3 MTHGT 与对比模型的实验结果

数据集	模型	$P@N$	$R@N$	$HR@N$
Movielens-1M	PinSage	0.415 1	0.095 4	0.928 9
	NGCF	0.486 6	0.115 3	0.959 6
	HIN2Vec	0.452 4	0.104 3	0.945 4
	HGT	0.465 4	0.108 4	0.950 8
	MTHGT	<b>0.504 1</b>	<b>0.127 9</b>	<b>0.967 0</b>
Last, FM	PinSage	0.231 3	0.105 5	0.748 9
	NGCF	0.293 1	0.134 1	0.871 5
	HIN2Vec	0.266 8	0.122 8	0.821 8
	HGT	0.288 9	0.132 5	0.864 6
	MTHGT	<b>0.331 8</b>	<b>0.151 6</b>	<b>0.913 4</b>

#### 4.3.2 消融实验分析

为了进一步验证 MTHGT 模型的有效性,探究稠密子图采样策略和多任务学习结构对模型推荐性能的影响,本文在 Last, FM 稀疏数据集上进行消融实验。其中, HGT 作为基线对比模型; HGT-d 是采用稠密子图采样策略的模型; HGT-m 是只添加多任务学习结构,不采用稠密子图采样策略的模型; MTHGT 是既采用稠密子图采样策略又添加多任务学习结构的模型。本次消融实验是通过增加或删减模型结构,来对比不同模型在  $N$  分别等于 5, 10, 20 时的精确率 ( $P@N$ ) 和召回率 ( $R@N$ )。实验结果如图 4 所示。

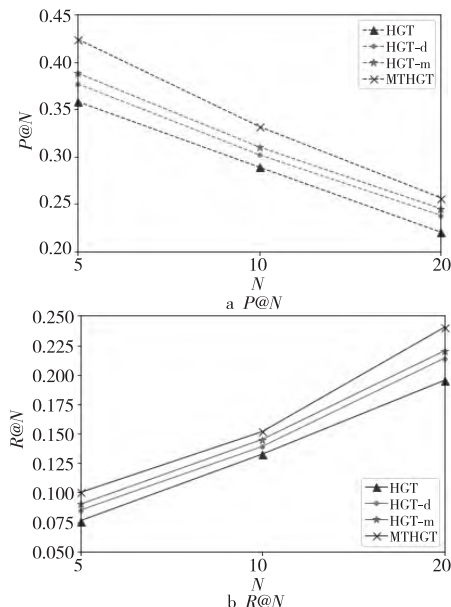


Figure 4 Results of ablation experiments

图 4 消融实验结果

从图 4 可知,无论是单独加入稠密子图采样策

略的 HGT-d 模型,还是单独加入多任务学习结构的 HGT-m 模型,都比 HGT 模型的推荐评测效果更好,说明这 2 种结构都能对模型推荐性能产生增益效果;比较 HGT-d 和 HGT-m 的增益效果,可以发现相比稠密子图采样策略,多任务学习结构的加入对模型性能提升有更大的作用;另外,把单独加入稠密子图采样和多任务学习结构的 HGT-d 和 HGT-m 模型的评估指标增益效果叠加,可以发现其增益效果与 MTHGT 模型的评估指标增益效果相似,说明这 2 个结构是比较独立的模块,同时加入模型不会对彼此产生明显的负效果影响。

## 5 结束语

本文针对现有基于图神经网络的方法存在的问题,考虑对异质图建模并融合多任务联合训练,提出基于多任务学习的图神经网络推荐模型。模型的核心思想在于借助图神经网络抽取异质图的丰富语义信息的同时,利用多任务学习避免模型过拟合,增强模型泛化能力,并通过权衡任务之间损失的权重避免多任务联合训练导致的负迁移学习。但是,本文提出的模型仍然存在一定的局限性,由于模型的大部分参数都来自图卷积网络,每个子任务都需要维护独立的图神经网络,模型复杂度与子任务个数成正比关系。因此,在后续的研究中,将考虑优化多任务学习框架结构,让多个任务共享图卷积网络参数。

## 参考文献:

- [1] Huang Le-le, Ma Hui-fang, Li Ning, et al. A collaborative filtering recommendation algorithm based on bipartite graph partitioning co-clustering[J]. Computer Engineering & Science, 2019, 41(11): 2040-2047. (in Chinese)
- [2] Li Xian, Zhao Xia, Zhang Ze-hua. A fuzzy recommendation method based on heterogeneous information network[J]. Computer Engineering & Science, 2020, 42(2): 334-340. (in Chinese)
- [3] Gilmer J, Schoenholz S S, Riley P F, et al. Neural message passing for Quantum chemistry[C]//Proc of the 34th International Conference on Machine Learning, 2017: 1263-1272.
- [4] Kipf T N, Welling M. Semi-supervised classification with graph convolutional networks[J]. arXiv:1609.02907, 2016.
- [5] Sun Y, Han J, Yan X, et al. PathsSim: Metapath-based top-k similarity search in heterogeneous information networks[J]. Proceeding of VLDB Endowment, 2011, 4(11): 992-1003.
- [6] Hu Z, Dong Y, Wang K, et al. Heterogeneous graph transformer[C]//Proc of the Web Conference, 2020: 2704-2710.
- [7] Wang Y, Tang S, Lei Y, et al. DisenHAN: Disentangled het-

- erogeneous graph attention network for recommendation[C]//Proc of the 29th ACM International Conference on Information & Knowledge Management, 2020;1605-1614.
- [8] Shi C, Yu P S. Heterogeneous information network analysis and applications[M]. Cham, Switzerland: Springer, 2017.
- [9] Tao Y, Wang C, Zhen L. HIN2Vec: Explore meta-paths in heterogeneous information networks for representation learning[C]//Proc of the 2017 ACM Conference on Information and Knowledge Management, 2017;1797-1806.
- [10] Dong Y, Chawla N V, Swami A. Metapath2vec: Scalable representation learning for heterogeneous networks[C]//Proc of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2017;135-144.
- [11] Wang X, Ji H, Shi C, et al. Heterogeneous graph attention Network[C]//Proc of the World Wide Web Conference, 2019;2022-2032.
- [12] Hong H, Guo H, Lin Y, et al. An attention-based graph neural network for heterogeneous structural learning[C]//Proc of the AAAI Conference on Artificial Intelligence, 2020; 4132-4139.
- [13] Ying R, He R, Chen K, et al. Graph convolutional neural networks for web-scale recommender systems[C]//Proc of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2018;974-983.
- [14] Berg R v d, Kipf T N, Welling M. Graph convolutional matrix completion[J]. arXiv:1706.02263, 2017.
- [15] Wang X, He X, Wang M, et al. Neural graph collaborative filtering[C]//Proc of the 42nd International ACM SIGIR Conference on Research and Development in Information Retrieval, 2019;165-174.
- [16] Wu S, Tang Y, Zhu Y, et al. Session-based recommendation with graph neural networks[C]//Proc of the AAAI Conference on Artificial Intelligence, 2019;346-353.
- [17] Cen Y, Zou X, Zhang J, et al. Representation learning for attributed multiplex heterogeneous network[C]//Proc of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2019;1358-1368.
- [18] Fan S, Zhu J, Han X, et al. Metapath-guided heterogeneous graph neural network for intent recommendation[C]//Proc of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2019;2478-2486.
- [19] Jin J, Qin J, Fang Y, et al. An efficient neighborhood-based interaction model for recommendation on heterogeneous graph[C]//Proc of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2020; 75-84.
- [20] Ruder S. An overview of multi-task learning in deep neural networks[J]. arXiv:1706.05098, 2017.
- [21] Ma X, Zhao L, Huang G, et al. Entire space multi-task model: An effective approach for estimating post-click conversion rate[C]//Proc of the 41st International ACM SIGIR Conference on Research & Development in Information Retrieval, 2018;1137-1140.
- [22] Ma J, Zhao Z, Yi X, et al. Modeling task relationships in multi-task learning with multi-gate mixture-of-experts[C]//Proc of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining, 2018;1930-1939.
- [23] Tang H, Liu J, Zhao M, et al. Progressive layered extraction (PLE): A novel multi-task learning (MTL) model for personalized recommendations[C]//Proc of the 14th ACM Conference on Recommender Systems, 2020;269-278.
- [24] Cipolla R, Gal Y, Kendall A. Multi-task learning using uncertainty to weigh losses for scene geometry and semantics [C]//Proc of 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition, 2018;7482-7491.

### 附中文参考文献:

- [1] 黄乐乐, 马慧芳, 李宁, 等. 基于二分图划分联合聚类的协同过滤推荐算法[J]. 计算机工程与科学, 2019, 41(11): 2040-2047.
- [2] 李娟, 赵霞, 张泽华. 基于异质信息网络的模糊推荐算法[J]. 计算机工程与科学, 2020, 42(2): 334-34.

### 作者简介:



**罗可劲**(1997-), 男, 广东罗定人, 硕士生, CCF 会员(E8959G), 研究方向为图神经网络和推荐系统。E-mail: lkj970319@163.com

**LUO Ke-jin**, born in 1997, MS candidate, CCF member(E8959G), his research interests include graph neural network and recommender system.



**刘广聪**(1970-), 男, 广东韶关人, 硕士生, 副教授, 研究方向为深度学习和数据挖掘。E-mail: liugc@gdut.edu.cn

**LIU Guang-cong**, born in 1970, MS, associate professor, his research interests include deep learning and data mining.



**杨文浩**(1997-), 男, 广东韶关人, 硕士生, 研究方向为深度学习和自然语言处理。E-mail: 2265205952@qq.com

**YANG Wen-hao**, born in 1997, MS candidate, his research interests include deep learning and natural language processing.